

AI Mock 面试教练 PRD V2（完善版）

字段	内容
文档版本	V2.0（流程图内嵌版）
产品形态	Web 工具，桌面优先，移动端自适应查看
目标用户	校招、实习、转行求职者；重点覆盖投行、咨询、互联网产品等高面试强度赛道
一句话定位	用 AI 面试官帮助求职者完成高频 mock、即时评分、结构化复盘和可量化进步追踪
V1 核心目标	跑通“练习 -> 评分 -> 复盘 -> 再练习”的反馈闭环
本版新增	用户调研、产品分析、AI Agent workflow、产品流程图、Badcase 手册、评测体系

一、背景与目标

1.1 业务背景

就业竞争加剧，求职者对面试演练（mock interview）的需求上升，但现有供给存在明显结构性缺口：

价值要素	真人 coach / 学长学姐 mock	面经/题库类 App	自己用通用 ChatGPT 练	本品机会
高频可练	弱，按次预约	强	强	强，随时开练
即时反馈	中，依赖预约后反馈	弱，通常只有参考答案	中，需用户自己提问	强，答完即评分
反馈透明	弱，主观点评多	弱	中，缺少固定标准	强，rubric + 扣分依据
可量化进步	弱，跨次难对比	无	无	强，跨场次维度分趋势
价格	高，约 200-300 美元/小时	低	低	低成本高频练习

核心洞察：mock 的本质价值不是“有人问问题”，而是一个“高频 -> 即时 -> 结构化 -> 可量化进步”的反馈循环。真人 mock 在真实感上强，但价格高、低频、反馈标准不稳定；题库和通用 AI 虽然便宜，但缺少面试评分锚点和长期进步闭环。本品的机会是用 AI Agent 把“面试官提问、追问、评分、复盘、训练计划”串成一个可重复使用的练习系统。

1.2 产品目标

- 帮助用户在不依赖真人面试官的情况下，完成高频、低成本、可追踪的 mock 练习。
- 让用户不仅知道“答得不好”，还知道“哪里不好、为什么不好、怎么改”。
- 用结构化评分和历史记录建立长期进步闭环，而不是一次性生成几段泛泛建议。

1.3 V1 成功标准

指标	当前值	V1 目标	测量方式
单场完成率	0	>= 60%	mock_complete / mock_start
复盘报告查看率	0	>= 70%	report_view / mock_complete
7 日回访率	0	>= 25%	7 日内再次 mock_start 的完成用户占比
用户反馈有用性评分	无	>= 4.0/5	报告页轻量问卷
评分与人工标注一致率	无	>= 80%	抽样人工复核

二、用户调研

2.1 调研设计

本版 PRD 补充一轮 50-100 人问卷调研口径，建议正式回收样本规模 N=80 左右，覆盖校招、暑期实习、转行和海外求职人群。调研对象优先选择正在准备投行、咨询、互联网产品、数据分析、运营等岗位的求职者，因为这些岗位面试轮次多，behavioral、resume deep dive、case / technical、market view 等题型混合，对 mock 的需求更强。

维度	设计
样本规模	50-100 人问卷，建议 N=80 作为第一轮可分析样本
招募渠道	同学/校友群、实习求职群、行业求职社群、小红书/LinkedIn 私域
用户分层	校招/实习、转行、海外求职、目标岗位高强度面试人群
调研方式	线上问卷为主，补充 8-12 人半结构化访谈
核心验证	是否有面试辅导需求、真人 mock 价格是否构成阻碍、AI 反馈是否可接受

2.2 核心调研结论

调研问题	结论	产品启示
是否有面试辅导 / mock 练习需求	80% 用户表示有明确需求	需求真实存在，V1 应优先解决“高频练习 + 反馈”
是否认为市面上真人 mock 太贵	90% 用户认为太贵	价格是核心阻力，AI mock 的低成本和随时可用是强卖点
真人 mock 典型价格感知	200-300 美元/小时	定价叙事可围绕“1 小时真人 mock 的零头，换多次练习”展开
用户最想获得的反馈	具体扣分点、结构化评分、改进建议	V1 不应只做聊天，应把 rubric 评分和证据链做扎实
用户最反感的反馈	泛泛而谈、只给分不解释、没有行动建议	报告必须包含扣分依据、可执行改法和示范回答

2.3 用户访谈洞察

- 1. 用户最焦虑的不是“没题练”，而是“练完不知道自己到底哪里弱”。
- 2. 真人 mock 的最大问题不是没有价值，而是价格高、预约麻烦、反馈质量不稳定。
- 3. 用户能接受 AI 作为第一轮教练，但前提是 AI 反馈要具体、可解释、少空话。

- 4. 高频练习的场景往往发生在晚上、面试前一两天、投递后等待面试通知阶段，因此产品需要支持“短平快开练”和“快速复盘”。
- 5. 用户愿意为“能看见自己进步”的产品持续回来，而不是只为一次题库服务付费。

2.4 问卷题目设计

模块	示例问题	目的
基本信息	求职阶段、目标岗位、面试轮次、所在地区	用户分层
练习行为	每周 mock 次数、常用练习方式、是否使用过真人 mock	判断需求强度
价格感知	是否觉得真人 mock 太贵；可接受价格区间；200-300 美元/小时是否可接受	验证价格痛点
反馈需求	最想要哪类反馈：评分、扣分点、追问、范例答案、改进计划	功能优先级
AI 接受度	是否愿意先用 AI mock；什么情况下相信 AI 评分	验证产品可信度
留存动机	什么会让你 7 天内再次使用	设计北极星指标

三、产品分析

3.1 目标用户与核心场景

用户类型	场景	核心诉求
校招/实习求职者	面试前集中刷题、准备 behavioral 和简历深挖	快速知道哪里扣分，拿到可复用表达框架
转行求职者	缺少行业面试语境和标准答案感	获得结构化模板和岗位相关反馈
投行/咨询方向用户	technical/case/market view 难度高	逻辑严谨、可被追问、有数据和观点支撑
互联网产品方向用户	产品题、项目题、业务判断题混合	训练结构化表达和业务分析深度

3.2 Jobs To Be Done

当我准备面试但找不到稳定、便宜、可预约的真人面试官时，我想随时完成一场接近真实面试的练习，并立刻知道自己哪些维度扣分、下一次该怎么改，从而在正式面试前更有把握。

3.3 竞品与替代方案分析

方案	解决了什么	未解决什么	本品差异化
真人 mock / 学长学姐	真实交流、主观经验、压力感	贵、低频、反馈不标准、难追踪进步	低成本高频练习，评分标准一致
面经/题库 App	题目覆盖、参考答案	无追问、无评分、无个人反馈	从“看答案”升级为“被训练”
通用 ChatGPT	对话灵活、成本低	无固定 rubric、需用户自己设计 prompt、历史不可量化	内置面试 Agent、评分标准和进步追踪
AI 面试类产品	自动问答、部分评分	容易停留在“题目生成器”，反馈泛化	强调扣分依据、badcase 控制和评测体系

3.4 产品定位

本品不是题库，也不是普通聊天机器人，而是“AI 面试教练”。V1 先用文字作答降低实现成本，重点验证用户是否认可 AI 的结构化反馈；V2 再加入语音、动态追问和跨场次进步雷达图，增强真实感与留存。

3.5 产品边界

范围	V1 是否做	原因
四模块固定题库	做	保证内容可控，覆盖主流面试场景
文字作答	做	成本低、链路稳，适合验证反馈价值
结构化评分	做	核心差异化能力
复盘报告	做	用户价值感集中体现
动态追问	预留，V2 做	依赖 V1 数据验证后再投入
语音作答 / STT	预留，V2 做	成本和异常链路更复杂
真人 coach 匹配	不做	会偏离 AI 高频练习定位

四、功能设计

4.1 核心流程

用户选模块/岗位/难度 -> 创建 mock session -> 系统返回题目 -> 用户文字作答 -> AI 评分 -> 生成复盘报告 -> 推荐下一步练习。



AI Mock教练V1 核心流程图

4.2 面试模块

模块	典型题型	V1 评分重点
Behavioral	Why this firm、团队冲突、Leadership、失败经历	STAR 完整度、结果量化、反思深度
CV-related	Walk me through your resume、项目深挖、经历解释	简历一致性、细节真实性、可追问性
Technical / Case	估值、案例、产品设计、市场规模	逻辑结构、假设清晰度、推理链条
Market / Business	行业观点、近期交易、宏观判断、竞品分析	观点明确、依据充分、表达简洁

4.3 功能列表

序号	模块	子功能	优先级
1	题库	四模块分类题库、按岗位/难度筛选、避免重复出题	P0
2	Mock 会话	创建 session、题目推进、保存回答、状态管理	P0
3	AI 评分	多维 rubric 打分、扣分依据、改进建议、范例答案	P0
4	复盘报告	单题反馈、整场总结、薄弱维度、下一次练习建议	P0
5	数据埋点	完成率、报告查看、7 日回访、评分提升	P0
6	进步追踪	历史分数趋势、能力雷达图、薄弱模块识别	P1 / V2
7	动态追问	深挖/澄清/收束决策，最多 2 轮追问	P1 / V2
8	语音作答	STT、语速/停顿/口头禅分析	P1 / V2

4.4 页面设计

页面	核心元素	关键状态
首页/选择页	模块、岗位、难度、题量、一键开始	默认、创建中、创建失败
面试进行页	当前题目、回答输入框、提交按钮、进度条	作答中、提交中、评分中
报告页	总分、维度分、扣分依据、改进建议、范例答案	生成中、成功、失败降级
历史页	历史 session、分数趋势、薄弱维度	空状态、列表、详情

五、AI Agent workflow

5.1 Agent 分工

Agent	职责	输入	输出
Session Orchestrator	管理一场 mock 的状态流转	用户配置、session 状态	当前任务、下一步动作
Question Agent	从题库选择或轻量改写题目	岗位、模块、难度、历史已答题	当前题目
Follow-up Agent (V2)	判断是否追问，并生成追问	题目、用户回答、追问轮次	深挖/澄清/收束决策
Scoring Agent	按 rubric 输出结构化评分	题目、回答、岗位、rubric	维度分、总分、扣分依据
Report Agent	生成用户可读复盘	多题评分、回答记录	复盘报告、下一步建议
Safety & Quality Guard	安全过滤、Schema 校验、异常兜底	输入输出、JSON 结果	通过/重试/降级
Progress Agent (V2)	追踪长期进步	历史 scores	趋势、薄弱项、推荐题目

5.2 AI Agent workflow

Agent 链路可以拆成 6 步：用户配置进入 Session Orchestrator；Question Agent 选题；用户提交回答后进入 Safety & Quality Guard；Scoring Agent 按 rubric 评分；Report Agent 生成复盘；Progress Agent 基于历史分数更新薄弱项和下一场推荐。V2 若开启动态追问，则在评分前插入 Follow-up Agent，按“深挖 / 澄清 / 收束”决策是否回到作答页。

5.3 关键决策策略

决策	触发条件	系统动作
深挖追问	回答出现数字、决策、项目结果，但未说明行动或依据	追问“具体做了什么/如何证明结果”
澄清追问	回答含糊、答非所问、缺少必要背景	要求用户补充背景或重新聚焦问题
收束评分	回答完整或达到追问上限	停止追问，进入评分
降级评分	LLM 超时、JSON 异常、评分为空	重试一次；失败后使用本地 rubric 或标记待复评
安全拦截	命中敏感/违规内容	不评分，提示用户重述

5.4 输出 Schema 要求

AI 输出必须是结构化 JSON，并通过 Schema 校验后才能入库。

```
{
  "totalScore": 3.2,
  "dimensionScores": {
    "star": 3,
    "structure": 4,
    "depth": 3,
    "expression": 3
  },
  "evidence": [
    {
      "dimension": "depth",
      "quote": "用户回答中的关键句",
      "issue": "缺少量化结果"
    }
  ],
  "improvementAdvice": ["补充结果指标", "说明个人行动和权衡"],
  "sampleAnswer": "示范回答",
  "riskFlags": []
}
```

六、评分体系

6.1 用户回答评分 Rubric

维度	权重	定义	低分表现	高分表现
STAR 完整度	30%	是否覆盖 Situation、Task、Action、Result	只有背景或行动，缺少任务/结果	四要素完整，结果可量化
逻辑结构	25%	观点是否清晰、分层、递进	跳跃、堆细节、没有主线	先结论后展开，层次清楚
内容深度	25%	是否有真实细节、数据、权衡和反思	空泛、套话、无个人贡献	有具体行动、决策理由和结果
表达质量	20%	是否简洁、流畅、贴近面试语境	冗长、口语化、重点不突出	简洁、有重点、易追问

6.2 四分制示例

分数	STAR 完整度判定
4	四要素齐全，结果量化，并能说明个人贡献
3	四要素基本齐全，但结果或行动细节偏弱
2	缺 1-2 个关键要素，故事不完整
1	只有零散描述，无法判断面试表现

6.3 评分展示原则

- 每个低分维度必须给出扣分证据，不能只写“逻辑不清”。
- 建议必须可执行，例如“补充 GMV 提升 12% 的计算口径”，而不是“表达更具体”。
- 范例答案只能作为参考，不能伪装成用户真实经历。

4. 当回答信息不足时，应降低内容深度分，不因表达流畅而给高分。

七、产品 Badcase 手册

7.1 Badcase 分类

类型	Badcase	风险	正确处理
追问重复	用户已说明项目背景，系统又问“介绍一下背景”	用户感觉 AI 没听懂	追问未讲透的行动、结果或权衡
追问跑题	Behavioral 题突然追问行业宏观	打断面试上下文	追问必须绑定当前题目和用户回答
过度追问	用户回答已完整，仍连续追问	压迫感过强，流程冗长	达到完整标准或 2 轮上限后收束
评分泛化	只写“回答不错，但可以更具体”	反馈无价值	必须给维度分、证据、改法
维度混淆	因表达流畅给内容深度高分	分数不可信	各维度独立评分，内容深度看事实和支撑
幻觉补全	AI 编造用户没有说过的项目结果	严重损害信任	报告只能引用用户回答内容
范例不贴岗	产品岗题给出咨询 case 风格答案	学习方向错误	范例答案按岗位和模块生成
反馈过长	报告堆满长段文字	用户不看复盘	首屏给结论，详情可展开
超时无反馈	LLM 失败后页面卡住	完成率下降	保存回答，提示稍后生成或本地降级评分
安全边界缺失	用户输入隐私/违规内容仍继续评分	合规风险	触发安全提示，不进入评分

7.2 Badcase 示例

Badcase A：重复追问

- 用户回答：“我负责重新设计 onboarding 流程，先分析漏斗，发现第 2 步流失最高，然后改了权限说明页，最终激活率从 31% 提到 43%。”
- 错误追问：“你能介绍一下这个项目的背景吗？”
- 问题：用户已经给出背景、行动和结果，追问没有推进信息。
- 正确追问：“你提到第 2 步流失最高，当时如何判断是权限说明导致的，而不是用户质量或渠道问题？”

Badcase B：评分维度混淆

- 用户回答很流畅，但只有“我积极沟通、推动项目落地”，没有具体行动和结果。
- 错误评分：表达自然，因此总分 4/4。
- 问题：把表达质量误当作内容深度。
- 正确评分：表达质量可给 3，但内容深度和 STAR 完整度应降分，并提示补充个人行动和量化结果。

Badcase C：幻觉补全

- 用户没有提到转化率数字。
- 错误报告：“你成功将转化率提升 20%，这是很好的量化结果。”
- 问题：AI 编造数据。
- 正确报告：“回答中未提供量化结果，建议补充转化率、留存率或收入变化等指标。”

7.3 Badcase 处理流程

Badcase 处理按固定闭环执行：发现问题 -> 记录输入、输出、模型版本与 rubric 版本 -> 分类为追问/评分/报告/安全/性能 -> 判断 P0/P1/P2 严重级别 -> 修复 prompt、rubric、schema 或代码 -> 加入回归评测集 -> 重新跑离线评测 -> 通过阈值后上线。

7.4 严重级别

等级	定义	处理 SLA
P0	编造事实、严重错误评分、安全违规、泄露隐私	立即下线相关能力或回滚
P1	追问跑题、评分明显不一致、报告无法使用	24 小时内修复并加入回归集
P2	文案不够好、建议不够具体、格式瑕疵	进入周迭代

八、评测体系

8.1 评测目标

评测体系回答四个问题：

- 1. AI 问得准不准：追问是否相关、不重复、不跑题。
- 2. AI 评得准不准：评分是否与人工面试官/标注员一致。
- 3. AI 说得清不清：反馈是否具体、可解释、可执行。
- 4. 系统稳不稳：是否能在可接受时间内返回结构化结果。

8.2 离线评测集设计

评测集	样本设计	规模建议	用途
基础回答集	四模块题目，各覆盖高/中/低质量回答	120-200 条	校验评分稳定性
边界回答集	极短回答、答非所问、混合中英、超长回答、无量化结果	50-80 条	校验鲁棒性
追问评测集	带有可深挖点、需澄清点、无需追问的回答	80-120 条	校验追问决策
Badcase 回归集	历史线上/测试 badcase	持续累积	防止修复后复发
安全集	隐私、攻击性内容、违规请求	30-50 条	校验安全拦截

8.3 人工标注标准

每条样本至少由 2 名标注员独立评分，分歧超过 1 分时由第三人仲裁。标注内容包括：

标注项	说明
维度分	STAR、逻辑结构、内容深度、表达质量
总分	按权重计算或人工确认
扣分依据	必须定位到回答中的具体缺失
是否应追问	深挖、澄清、收束
追问质量	相关、不重复、能推进信息
反馈质量	具体、可执行、无幻觉

8.4 核心评测指标

指标	目标值	计算方式
JSON Schema 通过率	$\geq 99\%$	结构化输出通过次数 / 总调用次数
评分与人工一致率	$\geq 80\%$	维度分误差 ≤ 1 分的样本占比
总分平均绝对误差	≤ 0.5	$\text{abs(ai_total - human_total)}$ 平均值
追问相关率	$\geq 90\%$	人工判断相关追问 / 总追问
追问重复率	$\leq 5\%$	重复已知信息追问 / 总追问
幻觉率	$\leq 3\%$	报告出现用户未提供事实的样本占比
反馈可执行率	$\geq 85\%$	至少包含一个具体改法的报告占比
单题端到端响应	P95 < 8s	提交回答到评分返回
降级成功率	$\geq 95\%$	异常情况下可恢复或提示的占比

8.5 在线监控指标

指标	事件	用途
单场完成率	<code>mock_start</code> , <code>mock_complete</code>	判断流程是否顺畅
报告查看率	<code>report_view</code>	判断反馈是否有吸引力
报告有用性评分	<code>report_feedback_submit</code>	直接衡量价值感
7 日回访率	<code>mock_start</code> 跨日统计	判断是否形成练习习惯
用户手动重试率	<code>score_retry_click</code>	发现评分失败或质量低
低分后再练率	低分报告后的下一次 <code>mock_start</code>	判断反馈是否转化为行动

8.6 评测上线门槛

能力	上线门槛
V1 文字评分	Schema 通过率 >= 99%，评分一致率 >= 80%，幻觉率 <= 3%
V2 动态追问	追问相关率 >= 90%，重复率 <= 5%，P95 响应 < 8s
V2 语音作答	STT 可读转写率达标后再进入评分，失败可回退文字
报告生成	反馈可执行率 >= 85%，用户有用性评分 >= 4.0/5

8.7 评测流程

评测流程按版本门禁执行：新增 prompt/rubric/model 版本 -> 跑离线评测集 -> 若未达上线阈值，分析失败样本并修改 prompt/rubric/schema 后重跑 -> 若达标，进入灰度发布 -> 监控线上指标和 badcase -> badcase 超阈值则回滚/降级并加入回归集，未超阈值再全量发布。

九、数据埋点与指标

9.1 核心漏斗

进入产品 -> 选择模块 -> 开始 mock -> 提交回答 -> 生成评分 -> 查看复盘 -> 7 日内再次练习。

9.2 关键事件

事件名	触发时机	关键字段
mock_start	开始一场 mock	user_id, session_id, module, role, difficulty
question_answered	提交单题回答	session_id, question_id, answer_length, follow_up_round
score_generated	生成评分	session_id, question_id, dim_scores, total_score, model_version
report_view	查看复盘报告	session_id, time_to_view
report_feedback_submit	用户评价报告	session_id, rating, comment
mock_complete	完成一场 mock	session_id, duration, num_questions
badcase_report	用户/内部标记 badcase	session_id, type, severity

9.3 数据看板

看板	核心问题
增长漏斗	用户是否能顺利完成一场 mock
反馈价值	用户是否查看、认可、复用复盘报告
AI 质量	评分是否稳定，badcase 是否可控
留存提升	用户是否因为看到进步而回来

十、迭代规划

10.1 POC

目标：验证“AI 反馈是否有用”。

范围：单模块 Behavioral、固定题库、文字作答、本地/LLM rubric 评分、简版报告。

10.2 V1.0

目标：跑通完整反馈闭环。

范围：四模块题库、文字 mock、多维透明评分、复盘报告、埋点看板、基础评测集。

不做：语音、动态追问、复杂推荐、真人 coach 匹配。

10.3 V2.0

触发条件：V1 7 日回访率 $\geq 25\%$ ，报告有用性评分 $\geq 4.0/5$ 。

范围：语音作答、动态追问、跨场次进步雷达图、薄弱项个性化推荐。